

# 遥感图像迁移学习——结题答辩

## 1. 项目背景、目的及意义

根据语义特征对遥感图像场景进行分类是一项具有挑战性的任务。因为遥感图像场景的类内变化较大，而类间变化有时却较小。不同的物体会以不同的尺度和方向出现在同一类场景中，而同样的物体也可能出现在不同的场景里。

以深度学习为代表的驱动方法，凭借其强大的特征学习和多层次表达能力，在遥感影像智能解译领域已得到广泛关注。但深度学习方法依赖海量的标注数据，而数据集的收集和人工标注需要耗费大量的人力成本，这一矛盾也使得该类方法在大区域、复杂场景下的遥感影像解译任务中仍然面临诸多挑战。另外，传统的分类方法具有一定的局限性，诸如针对高光谱遥感图像中存在“同物异谱”和“同谱异物”现象，以及其数据结构呈现高度非线性特点，基于统计识别模式的分类模型难以对其进行有效处理，仅利用光谱信息用于分类容易出现分类精度随维度增加而降低的现象。

迁移学习是一种运用已有知识对不同但相似领域问题进行求解的机器学习方法，与传统的机器学习相比，迁移学习不但可以解决训练样本不足的问题，还可以满足训练数据和测试数据服从不同分布的情况，同时迁移学习也能够将训练得到的模型在不同任务之间进行迁移和共享。将迁移学习与深度学习相结合，能够在保证深度模型所能达到的精度同时，发挥迁移学习分类速度快、对训练样本和硬件设备要求低等特点，近年来深度迁移学习已经在自然语言以及图像处理等方面取得了令人满意的效果。目前，在基于深度迁移学习的高光谱遥感图像分类方法中，最为主要的是对深度神经网络算法进行迁移，实现对不同领域的遥感图像进行分类。

在本项目中，团队将首先通过深度学习方式在高分辨率高光谱遥感影像中训练模型，然后将其迁移至低分辨率高光谱遥感影像，快速实现低分辨率高光谱遥感影像的地物分类，从而减少低分辨率遥感影像重新训练需要的时间成本和硬件成本。在此基础上，团队将对高分辨率高光谱遥感影像训练模型中的超参数、卷积层、数据集等因素进行探究，寻找出最恰当的训练模式和迁移方案，从时间成本和硬件成本两方面综合考虑出最合适的迁移方式。

## 2. 数据准备和制作

### 原始数据

本迁移学习的主要研究数据为高分2号高光谱遥感影像。实验使用7200\*6800，分辨率为10m的高分2号遥感影像作为源数据。对应的影像标签也是分辨率为10m的7200\*6800影像。影像标签的颜色和对应地物类别如下表

表 1 影像标签地物类别

地物	R	G	B
建筑物	255	0	0
农田	0	255	0
森林	0	255	255
草地	255	255	0
水域	0	0	255

### 实验数据制作

迁移学习首先需要在高分辨率影像上进行训练，得到训练模型。为了满足影像和标签能够实

现完全对应，确保后续训练工作正确、有序进行，需要对影像数据进行预处理。

1. 原有影像没有投影信息，需要对所有影像和标签进行投影定义，定义为 WGS84。定义投影后，确保原影像和标签影像能够完全重合
2. 在定义投影的基础上，将原影像通过双线性插值法重采样转为实验所需的低分辨率影像。重采样影像的分辨率为 40 米
3. 对原高分辨率影像的标签同样进行上述重采样工作。重采样工作完成后，确保低分辨率影像和其对应的标签能够完全重合
4. 对标签进行赋值。根据上述六种标签的 RGB 值，将标签影像转为单一波段的数值。具体转换映射表如下：

表 2 标签转换映射表

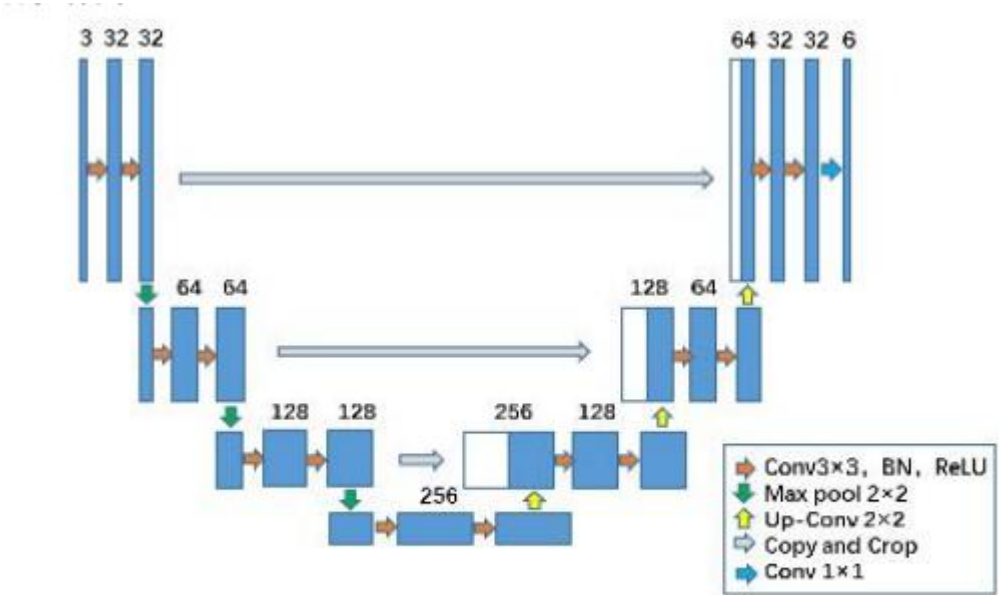
标签类型	建筑物	农田	森林	草地	水域	无标签
数值	1	2	3	4	5	0

训练前还需做训练集、测试集、预测集的分类和裁剪等工作

### 3 模型训练

#### U-net 介绍

U-Net 是常用的语义分割网络之一，它简单、高效、易懂、容易构建、可以从小数据集中训练。U-Net 是典型的编码器-解码器结构，左边为编码器部分，对输入进行下采样，提取抽象特征；右边为解码器部分，将编码结果进行上采样恢复至原图尺寸；中间采用跳跃连接结构进行特征融合。由于整个网络形似一个“U”，所以称为 U-Net。



U-Net 结构图

#### 训练过程

迁移学习的第一个步骤是对高分辨率影像进行训练，得到训练模型。为探究最合适的训练参数，需要对神经网络的层数、学习率、层数、归一化模型等参数进行调整后执行多次训练，并评估训练的准确率，得到最合适的训练模型。

受硬件条件、训练时间等因素制约，本团队采用的训练和测试方式如下：

1. 在 UNet.py 中，输入总共的训练次数、每多少次训练验证一次、输入波段数、输出类别数，然后运行 UNet.py 程序
2. 观察输出的 Loss 图像和验证准确率图像。如果 Loss 图像为下降趋势且趋向于平缓，验证准确率浮动不大，则为有效训练，如下图所示
3. 通过观察验证的准确率图，选择准确率最高的模型，或默认选择最后一个模型（在准确率差别不大的情况下），将这个模型载入 test\_img.py 中进行全图预测，输出预测图像
4. 在 ENVI 中打开测试结果进行评价分析




图 4 有效训练的 Loss 图像




图 5 有效训练的准确率图像

## 训练结论

（这部分我觉得不重要，可以到钟哥的论文里随便摘取截图）

## 4 模型迁移

### 迁移方法

在预训练模型训练完毕之后，要将其迁移至低分辨率。考虑到高分辨率图像和低分辨率图像的总体相似性，团队拟采用 Finetune 的迁移方法实现高分辨率到低分辨率的迁移。具体的迁移方法是：冻结预训练模型的部分卷积层（靠近输入的多数卷积层），训练剩下的卷积层（靠近输出的部分卷积层）和全连接层。在全连接层进行了修改，使其能够适应低分辨率的 Label 的输出，根据特征组合进行重新分类，这里类别没有区别，利用训练过程进行参数的微调。

简要的代码如下，注意这是伪代码

```
def Transfer():
    # Load pretrained model
    net = torch.load('model_transfer_epoch100.pkl')
    # frozen conv
    net.conv1.requires_grad = False
    net.conv2.requires_grad = False
    net.conv3.requires_grad = False
    net.conv4.requires_grad = False
    return net
```

迁移过程

迁移学习具有训练时长短、所需数据量少、在有预训练参数的情况下模型精度高的特点。基于上述特点，团队设置如下对照试验：

表 3 迁移学习实验表

组别	实验模式
对照组 1	预训练模型直接预测低分辨率遥感影像
对照组 2	从头训练低分辨率模型，使用完整的数据集，100epoch，lr=0.01
实验组 1	利用高分辨率模型进行迁移学习，使用完整的数据集，100epoch，lr=0.01
实验组 2	利用高分辨率模型进行迁移学习，使用随机选取的图片数量为原数据集一半的数据集，100epoch，lr=0.01
补充实验	对实验组 1 再以 lr=0.01 训练 200epoch，获取一个较高精度的低分辨率遥感影像分类模型

实验结果

团队继续使用之前的影像进行测试。影像和对应原标签如下



图 21 迁移学习测试影像




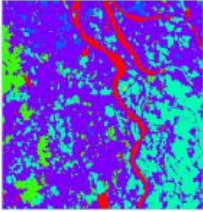
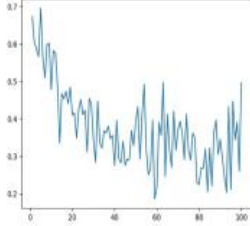
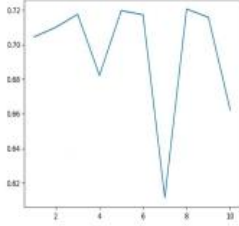


图 22 迁移学习测试影像标签

表 4 迁移学习测试结果

组别	输出影像	Loss 图	精确度图	训练时间	结论
对照组 1				8h	高分辨率模型完全不具备分类低分辨率遥感图像的能力，需要进行迁移学习
对照组 2				6h	从零开始训练低分辨率影像能保证精度但时间成本较高
实验组 1				3h	迁移学习组的 loss 明显收敛更快，且准确度更高，而且迁移学习由于冻结了大量卷积层的参数，减少

					了运算量，训练速度远快于非迁移学习组
实验组 2				2h	在数据量不足的情况下，迁移学习方法仍然能达到较高的预测精度和快速收敛，但是可能存在过拟合现象

在补充实验中团队额外模型训练了 200 个 epoch。最终 300 个 epoch 的训练只需要五小时即可完成，远低于从零开始训练的时间成本。且模型的预测结果已经相当优秀，如下图所示。




图 23 多次训练预测结果图

实验结果表明，迁移学习具有速度快、准确率高的特点，且其对数据量的要求较低。对于高分 2 号高光谱影像而言，选择 3 层 UNet 神经网络，学习率设置为 0.01 进行高分辨率影像训练，使用 Finetune 迁移方式进行迁移，冻结预训练模型的部分卷积层（靠近输入的多数卷积层），训练剩下的卷积层（靠近输出的部分卷积层）和全连接层，能够较好地实现高分辨率影像向低分辨率影像的模型迁移过程，能实现较高的迁移精度。另外，数据量的增加和训练次数的提升对于农田、森林等不具有明显特征和易混淆的地物预测效果的提升具有重大意义。

### 5 项目总结

## 项目成果推广及社会效益

高分辨率遥感影像向低分辨率影像分类模型的迁移学习是一项非常重要的技术,可以应用于各种军事、环保、地质、城市规划等领域。例如,在军事领域,军队可以使用无人机对敌方进行侦查,获取高分辨率的影像,但由于敌方可能采用了一些手段来模糊影像,从而降低了影像的分辨率,此时高分辨率向低分辨率影像分类的迁移学习技术将非常有用。该项目的成果还可以应用于商业领域,例如地图制作、房地产开发等。在某些特定情况,高分辨率影像可能有完整的标签,而低分辨率影像却没有,通过高分辨率遥感影像向低分辨率影像分类的迁移学习,我们可以更准确地获取地图信息,为人们提供更好的导航和定位服务。在遥感影像分类领域,遥感影像分类模型训练通常需要高昂的成本和大量的时间。而利用本项目的研究成果,可以将已经训练好的高分辨率分类模型迁移到低分辨率影像上进行分类,从而极大地缩短分类时间和降低成本,提高经济效益。迁移学习作为一种新的机器学习方法,正在逐渐成为遥感影像处理领域的重要手段。本项目的研究成果将会为迁移学习在遥感影像处理领域的应用提供有力支持,同时也将为人工智能在遥感影像处理领域的发展提供重要的思路 and 方向。

## 研究存在的不足或欠缺,尚需深入研究的问题等

不足和欠缺:

1. 样本数量不足。本研究中使用的数据集规模较小,不足以充分验证模型的泛化能力。在未来的研究中需要扩大数据集规模,以提高模型的鲁棒性。
2. 适用场景的局限性。本研究中仅考虑了高分辨率影像向低分辨率影像的迁移,而在实际应用中还存在其他不同场景下的遥感影像分类问题,如低分辨率影像向高分辨率影像,多光谱遥感影像、超分辨率遥感影像等。

尚需深入研究的问题:

1. 本研究中选择了一些高分辨率分类模型的超参数,但并没有对这些超参数的选择进行详细分析和优化。因此,在未来的研究中需要对超参数的选择进行更加深入的研究和优化,以提高模型的性能和泛化能力。
2. 不同地物类型的迁移情况各不相同,本研究在未来可以针对同一类地物的迁移情况进行探究,观察其迁移后预测成功率,并横向比较探寻其内在规律。

## 6 参考文献

- [1] 张东.国土资源遥感技术应用现状与发展趋势[J].农业与技术,2018,38(02):253.
- [2] 刘小波,尹旭,刘海波,汪敏,颜丙云.深度迁移学习在高光谱遥感图像分类中的研究现状与展望[J].青岛科技大学学报(自然科学版),2019,40(03):1-11.DOI:10.16351/j.1672-6987.2019.03.001.
- [3] 乔婷婷,李鲁群.结合数据增广和迁移学习的高分辨率遥感影像场景分类[J].测绘通报,2020(02):37-42.DOI:10.13474/j.cnki.11-2246.2020.0041.
- [4] 朱默研,侯景伟,孙诗琴,王彦卷.基于深度学习的遥感影像识别国内研究进展[J].测绘与空间地理信息,2021,44(05):67-73+85.
- [5] 林志斌,黄智全,颜林明.基于Unet的高分辨率遥感图像地物分类[J].电子质量,2020(11):69-76